

Rekurzív és egylépéses idősorelőrejelzők pontosságának vizsgálata

Lichter Bertalan

Szakos Máté

2025 tavasza

Kivonat

A gyakorlatban használt előrejelző modellektől az esetek többségében egy előre ismert előrejelzési horizonton szeretnénk tudni az idősorok jövőbeli értékeit. Ez elsősorban abból adódik, hogy a legtöbb alkalmazásban a döntések fix jövőbeli értékekre épülnek, például egy napra, hétre előrejelzett értékekre. Ha megvizsgáljuk a legelterjedtebb idősorelőrejelző modelleket, azt láthatjuk, hogy a legtöbb esetben rekurzív előrejelzést alkalmaznak, azaz a jövőbeli értékeket a múltbeli értékekből, pontonként számítják ki. Ez sokszor jó illeszkedést tesz lehetővé, azonban megjelenhet az úgynevezett drift jelenség. Ennek lényege, hogy a modell kis hibával előrejelzi a jövőbeli értékeket, azonban a hibák összeadódnak, így a jövőbeli előrejelzések pontossága csökkenhet. Ezzel szemben az egylépéses előrejelzés esetén a modell minden egyes jövőbeli értéket külön számít ki, így elkerülhető a drift jelenség. Utóbbi megközelítés hátránya azonban, hogy a legtöbb esetben rosszabb illeszkedést eredményez, mivel a függvény, amelyet megközelít, lényegesen bonyolultabb, mint a rekurzív előrejelzés esetén. Jelen házi feladat célja, hogy a két megközelítés pontosságát összehasonlítsa, és megvizsgálja, hogy melyik esetben érhető el jobb előrejelzési teljesítmény. Házi feladatunkban azt találtuk, hogy stacioner, periodikus idősorok esetén a rekurzív előrejelzés sokszor kevésbé pontos, mint az egylépéses előrejelzés. Az interferáló jel, illetve a fehér zaj mértéke nagy hatással van a pontosságra, azonban szinte minden esetben az egylépéses előrejelzés volt a pontosabb.

Háttér és motiváció

A problémakör egy gyakorlati alkalmazásban merült fel, amiben egy nagyon zajos és komplex nemlineáris, azonban valamelyest periodikus jelet kellett előrejelezni egy viszonylag hosszú időtávra. Intuitíven úgy tűnt, hogy a háttérben álló differenciálegyenletre való visszavezetés lenne a legjobb megoldás, amely kiértékelése megadja a jövőbeli értékeket (ez a rekurzív előrejelzés). Ennek a megközelítésnek az a motivációja, hogy lényegében egy differenciálegyenletet próbál megtanulni a modell, amely generálja a jelet. Ilyen módon nem csak pontos illeszkedést lehet elérni bizonyos esetekben, hanem jól magyarázható modelleket is kapunk [1]. Ez a következő formát öltene:

$$\begin{aligned}
\dot{x}(t) &\approx x(t + \Delta t) - x(t) = f(x(t), x(t - \Delta t), \dots, x(t - n \cdot \Delta t)) \\
&\quad + \epsilon(t + \Delta t) + \mathcal{O}(\Delta t) \\
\Rightarrow x(t + m \cdot \Delta t) &= x(t) \\
&\quad + \sum_{i=0}^{m-1} \left(f(x(t + i \cdot \Delta t), x(t + (i-1) \cdot \Delta t), \dots, x(t + (i-n) \cdot \Delta t)) \right. \\
&\quad \left. + \epsilon_{\text{rekurzív}}(t + m \cdot \Delta t) \right) \\
&= x(t) \\
&\quad + \sum_{i=0}^{m-1} f(x(t + i \cdot \Delta t), x(t + (i-1) \cdot \Delta t), \dots, x(t + (i-n) \cdot \Delta t)) \\
&\quad + \sum_{i=0}^{m-1} \epsilon_{\text{rekurzív}}(t + m \cdot \Delta t)
\end{aligned}$$

Ahogy az jól látszik, hogy a $\epsilon_{\text{rekurzív}}(t + \Delta t)$ hibák akkumulálódnak, így minél távolabbra szeretnénk előrejelezni, annál nagyobb hibával kell számolnunk.

Egy másik megközelítés, amelyet a gyakorlatban gyakran használnak, az egylépéses előrejelzés, amely a következő formát ölti:

$$x(t + m \cdot \Delta t) = f(x(t), x(t - \Delta t), \dots, x(t - n \cdot \Delta t)) + \epsilon_{\text{egylépéses}}(t + m \cdot \Delta t)$$

Ezen megközelítésnek az az előnye, hogy a hibája nem akkumulálódik, azonban egy nehezebb feladatot old meg, így a hibája általában nagyobb ($\epsilon_{\text{egylépéses}}(t + m \cdot \Delta t) > \epsilon_{\text{rekurzív}}(t + m \cdot \Delta t)$). Ennek ellenére képes pontosabb előrejelzést adni, mivel a rekurzív előrejelzés hibája felhalmozódik, míg az egylépéses előrejelzés hibája nem:

$$\text{az egylépéses modell jobb} \iff \epsilon_{\text{egylépéses}}(t + m \cdot \Delta t) < \sum_{i=0}^{m-1} \epsilon_{\text{rekurzív}}(t + m \cdot \Delta t)$$

A vizsgált idősor

A vizsgált idősor egy szint etikus, periodikus jel, amelyet a következő képlettel definiálunk:

$$\begin{aligned}
x(t) &= \sin(a \cdot t + b) \cdot \sin(c \cdot t) + \rho(t) + \epsilon(t), \\
s.t. \quad \rho(t) &= \sum_{i=1}^N \nu_i \sin(2\pi \cdot i \cdot f_{\text{base}} \cdot t + \phi_i), \\
\epsilon(t) &\sim \mathcal{N}(0, \sigma^2)
\end{aligned}$$

A jel egy nemlineáris, periodikus determinisztikus rész, egy periodikus interferáló zaj, és egy fehér zaj összegéből áll. Az interferáló jelet úgy állítottuk össze, hogy egy adott f_{base} alaphfrekvenciát, valamint annak felharmonikusait tartalmazza. Ez jól közelíti a valós életben előforduló periodikus zajokat, például az elektromos hálózatokból származó zajokat. A fehér zaj pedig egy normális eloszlású véletlenszerű zaj, amely az érzékelő hibáját hivatott modellezni.

A periodikus jel a következő paraméterekkel definiálható:

- a : a periodikus jel egyik komponensének frekvenciája
- b : a periodikus jel komponensei közti fáziseltolás
- c : a periodikus jel másik komponensének frekvenciája

Az interferáló zaj a következő paraméterekkel definiálható:

- N : az interferáló zaj komponenseinek száma
- ν_i : az interferáló zaj komponenseinek amplitúdója
- f_{base} : az interferáló zaj komponenseinek alaphfrekvenciája
- ϕ_i : az interferáló zaj komponenseinek fáziseltolása

A fehér zaj a következő paraméterekkel definiálható:

- σ : a fehér zaj szórása

Miért szintetikus jel?

A feladat során vizsgált idősor egy általunk konstruált, szintetikus jel, melyet azért választottunk, hogy tetszőlegesen hosszú jelet tudjunk generálni, hogy kedvünk szerint állíthassuk a zajokat, illetve a megfigyelési frekvenciát. Mindemellett talán a legfontosabb, hogy a kiértékelésnél így össze tudjuk hasonlítani a tiszta jellel, így a lehető legpontosabb képet kapva a modellek teljesítményéről. Ezzel szemben egy valós idősor bekorlátozna bennünket, hiszen nem tudnánk tetszőlegesen hosszú jelet generálni, és a zajok is adottak lennének. A szintetikus jel segítségével így nagy szabadságot ad, amellyel a különböző kísérletek során élünk is.

A tanuló modellek

Mindkét megközelítéshez (rekurzív és egylépéses előrejelzés) egyaránt egy 1d konvolúciós neurális hálózatot használtunk, amely a következőképpen van felépítve:

- **Bemenet**: a bemenet egy n hosszúságú ablak, amely az előző n időpont értékeit tartalmazza.

- **1D konvolúciós réteg:** a bemenetet egy 1d konvolúciós rétegen keresztül továbbítjuk, amely k szűrőt használ, és a kimenet mérete $n - k + 1$ lesz.
- **Aktivációs függvény:** a konvolúciós réteg kimenetét egy tanh aktivációs függvényen keresztül továbbítjuk, amely normalizálja a kimenetet, és segít a nemlineáris kapcsolatok modellezésében.
- **Laposító réteg:** a konvolúciós réteg kimenetét egy laposító rétegen keresztül továbbítjuk, amely a kimenetet egy vektorba alakítja.
- **Teljesen összekötött réteg:** a tanh aktivációs függvény kimenetét egy teljesen összekötött rétegen keresztül továbbítjuk, amely a kimenetet a kívánt méretre alakítja.
- **Kimenet:** a kimenet egy m hosszúságú vektor, amely az előrejelzett értékeket tartalmazza.

Az 1d konvolúciós réteg jól rá tud tanulni a periodikus és nemlineáris kapcsolatokra [2] (trend nélküli idősorok esetén), és képes kezelni a zajos adatokat is, így jól alkalmazható a feladat megoldására.

A megvalósítás az alábbi módon történik¹:

```
class Conv1DNN(nn.Module):
    def __init__(self, input_size, hidden_size, output_size, kernel_size):
        super(Conv1DNN, self).__init__()
        self.conv1 = nn.Conv1d(1, hidden_size, kernel_size)
        self.tanh = nn.Tanh()
        self.fc = nn.Linear(hidden_size * (input_size - kernel_size + 1), output_size)

    def forward(self, x):
        x = x.unsqueeze(1)
        x = self.conv1(x)
        x = self.tanh(x)
        x = x.view(x.size(0), -1)
        x = self.fc(x)
        return x
```

Hiperparaméterek megválasztása

A kísérletek során korán világossá vált, hogy mindkét megközelítés esetén nagy mértékben függ a modell teljesítménye a hiperparaméterek beállításától. A hiperparaméterek közé tartozik a konvolúciós réteg szűrőinek száma, a tanulási ráta, az ablak mérete, a teljesen összekötött réteg mérete és a tanulási ciklusok (epoch-ok) száma.

Megválasztásuk először pár manuális próbálkozással kezdődött, amellyel felmértük, hogy mely paraméter milyen tartományban működik jól. Ezt követően egy rácskereséses módszert alkalmaztunk, amelyben a hiperparaméterek külön-

¹A kódot saját implementációként mutatjuk be, de a PyTorch dokumentációja és példái alapján készült. Lásd: PyTorch Conv1d dokumentáció.

böző kombinációit teszteltük, és a legjobb teljesítményt nyújtó kombinációt választottuk ki.

Megvalósítás

A kódot tartalmazó jegyzetfüzetet itt lehet elérni. A megvalósítás során erősen építettünk a `pytorch` könyvtárra, amely lehetővé teszi a neurális hálózatok egyszerű és hatékony megvalósítását. A kiértékeléshez a `permetrics` könyvtárat használtuk, amely segít az idősorok előrejelzésének kiértékelésében. A kirajzolás-hoz pedig a `matplotlib` és `seaborn` könyvtárakat használtuk, amelyek lehetővé teszik a vizualizációk egyszerű és szép elkészítését.

Kísérletek

A kísérletek során minden esetben alkalmazva voltak a következő paraméterek:

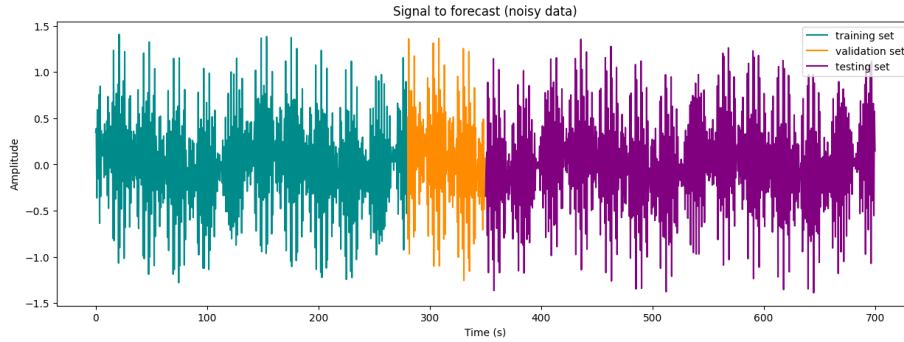
Paraméter	Érték
a	0.12123123
b	2.132123
c	5
σ	0.1
f_{base}	5
f_s	2

Utóbbi (f_s) a megfigyelési frekvencia, amely a jel mintavételezésének gyakoriságát határozza meg.

A generált jel 700 másodperc hosszú, amelyből az első 40%-ot tanulásra, 10%-ot validációra, és a maradék 50%-ot tesztelésre használtuk. Fontos megjegyezni, hogy mindenhol a zajos jelet használtuk, kivéve a tesztelésnél a kiértékeléshez; ezzel mimikálva a valós életben előforduló helyzeteket (ahol nem áll rendelkezésre a tiszta jel, azonban a modell helyességét a tiszta jelhez viszonyított hibája határozza meg).

Az eredmények kiértékelése

Az egyes modellek tanítását (hiperparaéterek optimalizációjával) követően a teljes teszt adathalmazon kiértékeltek (minden olyan ablakon, amely a visszatekintési ablakot figyelembe véve belefér a tesztelési adathalmazba) a modellek teljesítményét. Minden modell minden előrejezési horizonton ki volt értékelve három pontossági metrika szerint is. Így minden előrejelzési horizonthoz kapunk egy eloszlást. Minket ebből a kétdimenziós eloszlásból az utolsó időpillanathoz (maximális előrejelzési horizonthoz) tartozó eloszlások fontosak, illetve az előrejelzési horizont függvényében a metrikák átlaga és 95%-os konfidencia intervalluma.



1. ábra: A jel felosztása tanító, validációs és teszt partíciókra

Az utolsó időpillanathoz tartozó eloszlásokra egy Mann-Whitney U tesztet [3] hajtottunk végre, amely megmutatja, hogy a két eloszlás statisztikailag szignifikánsan különbözik-e egymástól. A próba megválasztása mögötti indoklás az, hogy a pontossági metrikák eloszlása nem normális, így a paraméteres tesztek nem alkalmazhatóak. A Mann-Whitney U teszt egy nem-paraméteres teszt, amely képes összehasonlítani két eloszlás középső értékét, és megmondani, hogy szignifikánsan különböznek-e egymástól. Továbbá fontos volt, hogy képes legyen különböző méretű minták összehasonlítására is, mivel a visszatekintési ablak mérete változhatott a különböző modellek esetén.

A pontossági metrikák

Determinisztikus együttható (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Átlagos Arkusztangens Abszolút Százalékos Hiba (MAAPE)

$$\text{MAAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{\arctan(y_i) - \arctan(\hat{y}_i)}{\arctan(y_i)} \right| \cdot 100$$

Normalizált Gyökös Középérték Négyzetes Hiba (NRMSE)

$$\text{NRMSE} = \sqrt{\frac{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}{\text{var}(y)}}$$

Alapeset (baseline)

A vizsgált jel paraméterei:

Paraméter	Érték
N	8
ν_i	e^{-i}
ϕ_i	$\frac{i}{2}$

Eredmények

A multi-step modell eredményei:

Statisztika / Metrika	R^2	MAAPE	NRMSE
Átlag	0.861215	0.533088	0.389559
Szórás	0.064623	0.109054	0.121122
Minimum	0.760632	0.175470	0.100543
25%	0.811130	0.493208	0.315494
50% (Medián)	0.839164	0.574209	0.438298
75%	0.908922	0.607534	0.477222
Maximum	0.990334	0.668871	0.546258

A single-step modell eredményei:

Statisztika / Metrika	R^2	MAAPE	NRMSE
Átlag	0.748613	0.605215	0.563616
Szórás	0.109455	0.089643	0.158023
Minimum	0.450480	0.345066	0.285388
25%	0.677587	0.547901	0.467984
50% (Medián)	0.776785	0.640956	0.530587
75%	0.815945	0.670578	0.680598
Maximum	0.924577	0.732448	0.958992


Mann-Whitney U-próba eredményei:

R^2	MAAPE	NRMSE
szignifikáns	szignifikáns	szignifikáns


A próbát 95%-os konfidencia mellett végeztük el.

Konstans amplitúdójú felharmonikusok

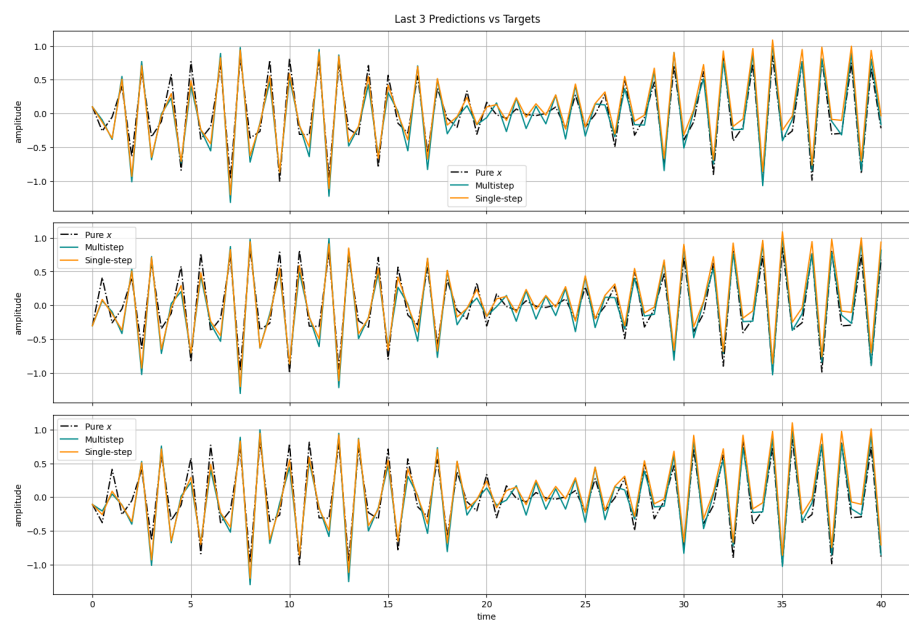
A vizsgált jel paraméterei:



2. ábra: A metrikák eloszlásának ábrázolása hisztogramokon



3. ábra: A metrikák értékeinek előrejelzési horizont szerinti változásainak ábrázolása vonaldiagramokon



4. ábra: Az utolsó 3 predikció során a predikált és a valós értékek összehasonlítása

Paraméter	Érték
N	8
ν_i	0.05
ϕ_i	$0.5 * i$

Eredmények

A multi-step modell eredményei:

Statisztika / Metrika	R^2	MAAPE	NRMSE
Átlag	0.996012	0.155957	0.060017
Szórás	0.002521	0.039808	0.018727
Minimum	0.987715	0.059417	0.029973
25%	0.994496	0.124806	0.044415
50% (Medián)	0.997040	0.152023	0.054228
75%	0.998013	0.185046	0.073972
Maximum	0.999098	0.262619	0.110965

A single-step modell eredményei:


Statisztika / Metrika	R^2	MAAPE	NRMSE
Átlag	0.956486	0.292970	0.175567
Szórás	0.009180	0.033163	0.015822
Minimum	0.932472	0.216166	0.141025
25%	0.948622	0.269446	0.161697
50% (Medián)	0.956709	0.289023	0.176190
75%	0.964651	0.313658	0.189437
Maximum	0.974404	0.388278	0.211980

Mann-Whitney U-próba eredményei:

R^2	MAAPE	NRMSE
szignifikáns	szignifikáns	szignifikáns

A próbát 95%-os konfidencia mellett végeztük el.

Mindkét modell teljesítménye javulást mutatott az előző állapothoz képest, azonban a multistep modell jelentősen jobb eredményeket ért el, egyértelműen felülmúlva a single-step megközelítést.




5. ábra: A metrikák eloszlásának ábrázolása hisztogramokon


Azonos fázisú felharmonikusok

A vizsgált jel paraméterei:

Paraméter	Érték
N	8
ν_i	e^{-i}
ϕ_i	0



6. ábra: A metrikák értékeinek előrejelzési horizont szerinti változásainak ábrázolása vonaldiagramokon



7. ábra: Az utolsó 3 predikció során a predikált és a valós értékek összehasonlítása

Eredmények

A multi-step modell eredményei:

Statisztika / Metrika	R^2	MAAPE	NRMSE
Átlag	0.824305	0.582514	0.452977
Szórás	0.069269	0.119868	0.123881
Minimum	0.727687	0.190561	0.134771
25%	0.772817	0.542082	0.390751
50% (Medián)	0.796647	0.633729	0.502453
75%	0.868249	0.663283	0.540860
Maximum	0.982459	0.715664	0.614921

A single-step modell eredményei:

Statisztika / Metrika	R^2	MAAPE	NRMSE
Átlag	0.804158	0.541396	0.482865
Szórás	0.087801	0.107451	0.133974
Minimum	0.594845	0.270309	0.219784
25%	0.749299	0.467209	0.400087
50% (Medián)	0.816612	0.560052	0.468941
75%	0.859210	0.628328	0.571633
Maximum	0.955980	0.712459	0.782898

Mann-Whitney U-próba eredményei:

R^2	MAAPE	NRMSE
szignifikáns	nem szignifikáns	szignifikáns

A próbát 95%-os konfidencia mellett végeztük el. A két modell teljesítménye annyira hasonló volt, hogy a MAAPE mutató esetében a különbség statisztikailag nem szignifikánsnak bizonyult (Mann–Whitney U teszt alapján). A multistep modell pontossága nem javult érdemben az alaphelyzethez képest, míg a single-step modell esetében enyhe teljesítménynövekedés figyelhető meg.

Azonos fázisú, azonos amplitúdójú felharmonikusok

A vizsgált jel paraméterei:

Paraméter	Érték
N	8

Paraméter	Érték
ν_i	0.05
ϕ_i	0

Eredmények

A multi-step modell eredményei:

Statisztika / Metrika	R ²	MAAPE	NRMSE
Átlag	0.996943	0.141795	0.052993
Szórás	0.001832	0.038001	0.015380
Minimum	0.990254	0.063674	0.029800
25%	0.995883	0.114157	0.040606
50% (Medián)	0.997641	0.136857	0.048513
75%	0.998355	0.166824	0.064159
Maximum	0.999107	0.258390	0.097862

A singe-step modell eredményei:

Statisztika / Metrika	R ²	MAAPE	NRMSE
Átlag	0.983068	0.268878	0.124674
Szórás	0.008837	0.045244	0.031973
Minimum	0.955019	0.180249	0.080115
25%	0.977305	0.238641	0.098538
50% (Medián)	0.985808	0.258839	0.116803
75%	0.990101	0.296830	0.149235
Maximum	0.993446	0.417857	0.211316


Mann-Whitney U-próba eredményei:

R ²	MAAPE	NRMSE
szignifikáns	szignifikáns	szignifikáns


A próbát 95%-os konfidencia mellett végeztük el. Mindkét modell teljesítménye javulást mutatott az alapállapothoz képest, azonban a multistep modell jelentősen jobb eredményeket ért el, egyértelműen felülmúlva a single-step megközelítést.

Sok felharmonikus


A vizsgált jel paraméterei:




8. ábra: A metrikák eloszlásának ábrázolása hisztogramokon




9. ábra: A metrikák értékeinek előrejelzési horizont szerinti változásainak ábrázolása vonaldiagramokon



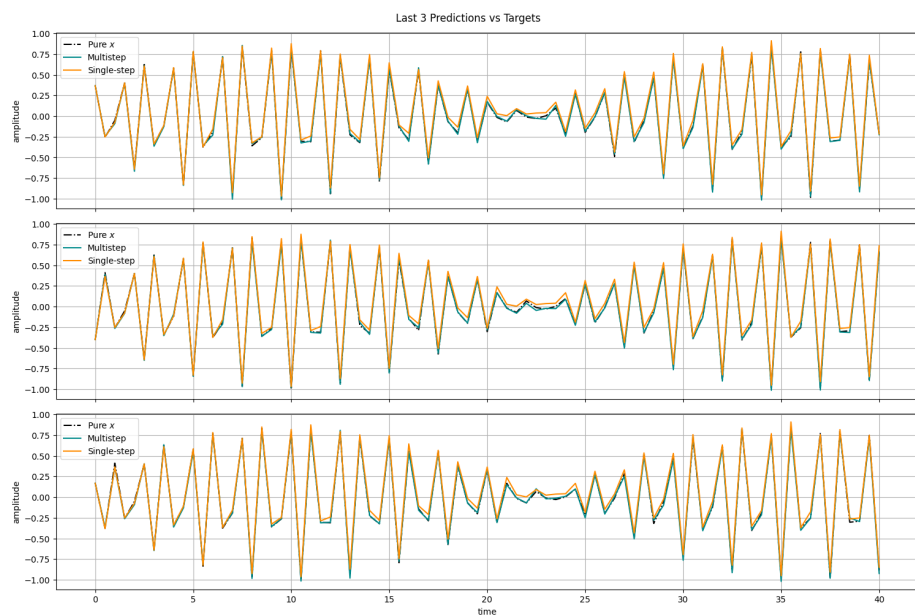
10. ábra: Az utolsó 3 predikció során a predikált és a valós értékek összehasonlítása



11. ábra: A metrikák eloszlásának ábrázolása hisztogramokon



12. ábra: A metrikák értékeinek előrejelzési horizont szerinti változásainak ábrázolása vonaldiagramokon



13. ábra: Az utolsó 3 predikció során a predikált és a valós értékek összehasonlítása

Paraméter	Érték
N	1000
ν_i	e^{-i}
ϕ_i	$\frac{i}{2}$

Eredmények

A multi-step modell eredményei:

Statisztika / Metrika	R^2	MAAPE	NRMSE
Átlag	0.847434	0.545867	0.416204
Szórás	0.062518	0.109039	0.115635
Minimum	0.767075	0.233465	0.133130
25%	0.800567	0.502339	0.362277
50% (Medián)	0.820599	0.592896	0.468674
75%	0.884667	0.618499	0.500377
Maximum	0.983496	0.671836	0.539017

A single-step modell eredményei:


Statisztika / Metrika	R^2	MAAPE	NRMSE
Átlag	0.776035	0.576163	0.528561
Szórás	0.104149	0.120279	0.168768
Minimum	0.533675	0.249557	0.193142
25%	0.707580	0.508881	0.415826
50% (Medián)	0.774476	0.615958	0.534799
75%	0.848639	0.666859	0.654348
Maximum	0.965065	0.737749	0.880469

Mann-Whitney U-próba eredményei:


R^2	MAAPE	NRMSE
szignifikáns	szignifikáns	szignifikáns

A próbát 95%-os konfidencia mellett végeztük el.


Az egylépéses modell egy kicsit, a hisztogramokon alig látható mértékben erősödött. Ezzel szemben a multistep modell predikciós pontossága romlott: az előnye minimálisra csökkent, bár az R^2 és NRMSE mutatók alapján a különbség még mindig statisztikailag szignifikáns. Fontos megjegyezni, hogy MAAPE alapján a multistep modell kifejezetten gyengébben szerepelt.



14. ábra: A metrikák eloszlásának ábrázolása hisztogramokon



15. ábra: A metrikák értékeinek előrejelzési horizont szerinti változásainak ábrázolása vonaldiagramokon



16. ábra: Az utolsó 3 predikció során a predikált és a valós értékek összehasonlítása

Összefoglalás

A kísérletek során sikerült bemutatni, hogy a rekurzív és egylépéses előrejelzés is képes jól teljesíteni a vizsgált idősor előrejelzésében, azonban legtöbb esetben az egylépéses előrejelzés volt a jobb teljesítményű (különösen a hosszú távú előrejelzésnél). A rekurzív előrejelzés esetén a hibák felhalmozódása miatt a hosszú távú előrejelzés pontossága csökkent, míg az egylépéses előrejelzés esetén a hibák nem halmozódtak fel, így a hosszú távú előrejelzés is pontosabb volt.

Limitációk

A házi feladat során csupán egy architektúrát vizsgáltunk, egyetlen idősoron. Előfordulhat, hogy más architektúrák vagy idősorok esetén más eredmények születnének. Elképzelhetőek olyan modellek is, amelyek nem tisztán az egyik vagy más megközelítést használják, hanem egyesítik a rekurzív és egylépéses előrejelzést, így kihasználva mindkét megközelítés előnyeit [4]. A rekurzív előrejelzés esetén nem alkalmaztunk teacher forcing-ot, amely szintén javíthatná a modell teljesítményét [5].

Irodalomgyűjtemény

- [1] K. Egan, W. Li, és R. Carvalho, „Automatically discovering ordinary differential equations from data with sparse regression”, *Communications Physics*, köt. 7, sz. 1, jan. 2024, doi: 10.1038/s42005-023-01516-2.
- [2] S. Kiranyaz, T. Ince, O. Abdeljaber, O. Avci, és M. Gabbouj, „1-D Convolutional Neural Networks for Signal Processing Applications”, in *ICASSP 2019 - 2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2019, o. 8360–8364. doi: 10.1109/ICASSP.2019.8682194.
- [3] P. E. McKnight és J. Najab, „Mann-Whitney U Test”, *The Corsini encyclopedia of psychology*, o. 1–1, 2010.
- [4] S. B. Taieb, R. J. Hyndman, és mtsai., *Recursive and direct multi-step forecasting: the best of both worlds*, köt. 19. Department of Econometrics and Business Statistics, Monash Univ., 2012.
- [5] T. von Neumann és mtsai., „End-to-end training of time domain audio separation and recognition”, in *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, IEEE, 2020, o. 7004–7008.